

# Visie voor semantische robotnavigatie in ziekhuisgangen

**Olivier VAN DEN EEDE**

Promotor(en): Prof. dr. ir. Toon Goedemé

Co-promotor(en): Filip Reniers

Masterproef ingediend tot het behalen van  
de graad van master of Science in de  
industriële wetenschappen: Electronica-ICT  
afstudeerrichting ICT

Academiejaar 2018 - 2019

©Copyright KU Leuven

Zonder voorafgaande schriftelijke toestemming van zowel de promotor(en) als de auteur(s) is overnemen, kopiëren, gebruiken of realiseren van deze uitgave of gedeelten ervan verboden. Voor aanvragen i.v.m. het overnemen en/of gebruik en/of realisatie van gedeelten uit deze publicatie, kan u zich richten tot KU Leuven Technologicampus De Nayer, Jan De Nayerlaan 5, B-2860 Sint-Katelijne-Waver, +32 15 31 69 44 of via e-mail [iiw.denayer@kuleuven.be](mailto:iiw.denayer@kuleuven.be).

Voorafgaande schriftelijke toestemming van de promotor(en) is eveneens vereist voor het aanwenden van de in deze masterproef beschreven (originele) methoden, producten, schakelingen en programma's voor industrieel of commercieel nut en voor de inzending van deze publicatie ter deelname aan wetenschappelijke prijzen of wedstrijden.

# Inhoudsopgave

<b>Inhoud</b>	<b>iv</b>
<b>Figurenlijst</b>	<b>v</b>
<b>Acroniemen</b>	<b>vi</b>
<b>1 Probleemstelling</b>	<b>1</b>
<b>2 Literatuurstudie</b>	<b>2</b>
2.1 Indoor navigatie & visie . . . . .	2
2.2 Object detectie . . . . .	2
2.2.1 Traditionele beeldverwerking . . . . .	3
2.2.2 Convolutional neural network . . . . .	3
2.3 Object tracking . . . . .	5
2.4 Image segmentation . . . . .	6
<b>3 Uitwerking</b>	<b>8</b>
3.1 Object detectie . . . . .	8
3.1.1 Annotatie beeldmateriaal . . . . .	9
3.1.2 Training YOLOv2 . . . . .	10
3.2 Perspectiefpunt detectie . . . . .	10
3.2.1 Hoogste vloerpixel segmentatie . . . . .	10
3.2.2 Vloerlijn kruising . . . . .	11
3.2.3 Perspectieflijn kruising . . . . .	11
3.3 Omgevingsmeting . . . . .	13
3.3.1 Camera kalibratie . . . . .	14
3.4 Semantische kaart . . . . .	14
3.5 Lokalisatie . . . . .	14

---

<b>4 Resultaten</b>	<b>15</b>
<b>5 Besluit</b>	<b>16</b>
<b>A CVAT naar YOLO conversie</b>	<b>19</b>

# Lijst van figuren

2.1	De lagen van een CNN volgens het YOLO [12] detection system. . . . .	4
2.2	Het SegNet [2] segmentatie netwerk. . . . .	7
3.1	Overzicht van het programma . . . . .	8
3.2	ResNet segmentatie van 1 input frame. . . . .	11
3.3	<b>Linksboven:</b> vloersegmentatie, <b>Rechtsboven:</b> Canny-edgedetectie, <b>Linksonder:</b> alle Hough lijnen, <b>Rechtsonder:</b> filtering van lijnen . . . . .	12
3.4	<b>Links:</b> Canny-edgedetectie op hele afbeelding. <b>Rechts:</b> Hough lijnen uit edge detectie. . . . .	12
3.5	Schematische voorstelling omgevingsmeting . . . . .	13

# Acroniemen

**AGV** Autonoom Geleid Voertuig. 1

**CNN** Convolutional Neural Network. 4, 5, 6, 7, 9

**CVAT** Computer Vision Annotation Tool. 9

**EM** Expectation-Maximization. 5

**HOG** Histogram of Oriented Gradients. 3

**HSI** Hue Saturation Intensity. 3

**LSTM RNN** Long Short Term Memory Recurrent Neural Network. 6

**OCR** Optical Character Recognition. 2, 3

**RANSAC** Random Sample Consensus. 3, 6

**ReLU** Rectified Linear Unit. 5

**RGB** Rood Groen Blauw. 1, 2, 4, 7, 8, 9, 13

**ROI** Region Of Interest. 5

**ROLO** Recurrent YOLO. 6

**SIFT** Scale-Invariant Feature Transform. 3, 5

**SVM** Support Vector Machine. 3, 6

**YOLO** You Only Look Once. 5, 6, 9, 10

# Hoofdstuk 1

## Probleemstelling

Ziekenhuizen kampen al langer met personeelstekorten en een hoge werkdruk voor het zorgpersoneel. Een deel van dit probleem komt doordat ze ook instaan voor de textiellogistiek en de goederenstroom. Dit probleem zou aangepakt kunnen worden met behulp van automatisatie van de transporten van textiel, karren en bedden. Deze automatisatie staat momenteel nog niet zo ver, omdat vergeleken met de industrie het moeilijk is om de volledige infrastructuur aan te passen, en deze aanpassingen meestal niet overweg kunnen met het bestaande logistiek materiaal. Een Autonoom Geleid Voertuig (AGV) zou gebruikt kunnen worden om het transport van karren en bedden te automatiseren binnen de logistieke gangen van het ziekenhuis.

Dit voertuig moet vanzelf kunnen navigeren in de gangen van een ziekenhuis en weten waar het zich op elk moment bevindt. Om dit te realiseren wordt het voertuig uitgerust met een aantal sensoren en een Rood Groen Blauw (RGB) camera om de omgeving te observeren. Voor navigatie beschikt het AGV over een semantische kaart. Dit is een kaart waarop aangeduid staat wat voor objecten er te zien zijn (muren, deuren, bordjes, verlichting, ..) samen met de afmetingen, positie en oriëntatie van deze tags.

Het doel van deze masterproef is het onderzoeken welke objecten/features er aanwezig zijn in de logistieke gangen van een ziekenhuis en op basis daarvan beeldverwerkingstechnieken te zoeken die geschikt kunnen zijn voor detectie en tracking van deze objecten. Deze detecties kunnen dan gebruikt worden om de locatie van de robot te bepalen op basis van de kaart. Vervolgens is het de bedoeling dat de robot vertrekt vanop een gekende locatie en d.m.v. zijn kaart en de objecten die hij detecteert in zijn omgeving autonoom kan navigeren naar een eindpunt.

## Hoofdstuk 2

# Literatuurstudie

### 2.1 Indoor navigatie & visie

Op visie gebaseerde navigatie is een onderwerp dat zeer vaak onderzocht wordt. Oudere onderzoeken zoals [19] maken gebruik van een robot met een RGB camera die zonder kaart informatie navigeert. De enige informatie die gegeven wordt is een eenvoudige object beschrijving van de gang en een beschrijving van een deur met een deurnummer ernaast. Met enkel een deurnummer als doel vertrekt de robot door de gang, en houdt zichzelf parallel met de muren door gebruik te maken van andere sensoren. Eens er een deur in beeld komt, worden er een aantal features(randen) herkend in het beeld. Nadat hun algoritme de deuren herkend kan er via Optical Character Recognition (OCR) op het deurnummer worden nagegaan of het doel bereikt is. Dit is uiteraard een zeer eenvoudige techniek omdat de robot geen begrip heeft van de omgeving, en moeilijk plaatsen t.o.v elkaar kan onderscheiden.

Nieuwere technieken zoals [7] maken gebruik van RGB-D camera's zoals bijvoorbeeld een kinect waardoor ze ook over diepte-informatie beschikken. Die diepte info kan dan gebruikt worden om heel de omgeving in 3d te mappen en op basis van de effectief gemeten positie te navigeren. Een andere manier om een 3d representatie van de omgeving te verkrijgen zoals [15] is gebruik te maken van stereovisie. Hierbij wordt de informatie van 2 RGB camera's die op een vaste afstand van elkaar staan gecombineerd om diepte informatie te verzamelen.

In dit onderzoek gaan we ons echter beperken tot één enkele RGB camera.

### 2.2 Object detectie

Een belangrijk aspect van dit onderzoek is het detecteren van individuele objecten in het beeld van één enkele RGB camera. De te detecteren objecten zijn op voorhand vastgelegd, en zijn afhankelijk van de ruimte waarin de robot zich bevindt.

In de logistieke gangen van een ziekenhuis zijn er heel wat objecten die we kunnen detecteren, een kleine selectie van deze objecten zijn:



- Pictogrammen;
- Brandblussers;
- Deurklinken.

Voor deze objecten gaan we kijken naar detectietechnieken uit de traditionele beeldverwerking, en naar meer *state-of-the-art* technieken.

### 2.2.1 Traditionele beeldverwerking

In openbare gebouwen zijn er heel wat pictogrammen te vinden zoals bijvoorbeeld nooduitgang, hoogspanning en brandblusser. Deze pictogrammen hebben steeds een specifieke vorm, kleur en symbool. De literatuur over pictogramdetectie is schaars. De techniek die voorgesteld wordt door [17] gebruikt een zeer eenvoudige edge detectie met OCR om eventuele letters op pictogrammen te lezen, dit is echter minder relevant omdat niet op elk pictogram tekst aanwezig is. Pictogrammen kunnen echter wel vergeleken worden met verkeersborden die bijna dezelfde kenmerken hebben. De aanpak van [6] is om 2 soorten features in een beeld te onderscheiden. Enerzijds detecteren ze vormen op basis van kleurranden en anderzijds wordt de afbeelding omgezet naar Hue Saturation Intensity (HSI) waaruit enkel de hue gebruikt wordt. De hue is de belangrijkste component voor het onderscheiden van kleuren omdat er zo geen rekening wordt gehouden met de hoeveelheid licht en schaduwen. Een recenter onderzoek [20] bouwt voort op deze technieken, maar hier berekenen ze de Histogram of Oriented Gradients (HOG) features van het beeld. Vervolgens wordt er gebruik gemaakt van een Support Vector Machine (SVM) om te bepalen waar er zich een match bevindt.

!!! TODO support vector machine

De vorm en kleur features kunnen dan gecombineerd worden om de positie van een mogelijke match te vinden. Eens er een mogelijke bounding box rond de mogelijke match gevonden is, kan er geprobeerd worden een template te matchen om het effectieve pictogram te achterhalen. Het grootste probleem bij de techniek van [6] is dat hun gebruikte template matching techniek niet robuust is tegen schaalinvariantie. Bij [20] maken ze voor de herkenningfase gebruik van Scale-Invariant Feature Transform (SIFT)[10] features en kleur informatie. Hierdoor is het probleem van schaal invariantie grotendeels opgelost. Hierbij worden de SIFT features van de kandidaat matches en de templates vergeleken, en wordt er een gemiddelde genomen van de verschillen tussen hue, saturation en value. Door middel van Random Sample Consensus (RANSAC) en een threshold wordt er bepaald welke matches gebruikt worden. Deze techniek zou gebruikt kunnen worden voor het detecteren van pictogrammen.


### 2.2.2 Convolutional neural network

De laatste jaren in het domein van beeldverwerking wordt er steeds meer gegrepen naar deep learning technieken. Dit komt omdat de rekenkracht van computers steeds beter en beter wordt,

en de resultaten die bekomen worden met neurale netwerken de traditionele manieren overtreffen op verschillende vlakken. Een deep learning techniek die veel gebruikt wordt in de beeldverwerking is een Convolutional Neural Network (CNN).

Een CNN is een supervised deep learning techniek die gebruikt kan worden om verschillende beeldverwerkende taken uit te voeren. Als een traditioneel neurale netwerk gebruikt zou worden voor een afbeelding van 448 bij 448 pixels, zou er bij elke inwendige laag een paar miljoen variabele gewichten aanwezig moeten zijn, dit zou leiden tot een veel te complex netwerk. Daarom wordt er gebruikgemaakt van een CNN, dit is eigenlijk een neurale netwerk waarbij niet alle neuronen met elkaar verbonden zijn.

Een CNN kan bestaan uit meerdere lagen die meestal een combinatie zijn van 'convolutional-layers' en 'fully connected-layers'. Elk van deze lagen bevat een aantal neuronen met elk een eigen set van gewichten. Het doel van een CNN is om de gewichten zodanig bij te stellen dat data die aan de eerste laag (de input laag) gegeven wordt een verwacht resultaat geeft aan de laatste laag (de output/classificatie laag). Deze laatste laag kan men de classificatielaag noemen, en geeft een representatie van wat het netwerk denkt dat er aan de input staat. In figuur 2.1 is een voorbeeld zichtbaar van een CNN met de verschillende soorten lagen.



**Figuur 2.1:** De lagen van een CNN volgens het YOLO [12] detection system.

Een 'convolutional-layer' of convolutie-laag is een laag die een convolutie operatie uitvoert op zijn input. Dit wil zeggen dat de input verdeeld wordt in regio's van bijvoorbeeld 7x7 pixels, deze 49 pixels zijn verbonden met 1 neuron in de volgende inwendige laag. Als dit 7x7 masker wordt opgeschoven met 1 pixel, verkrijgen we de input voor aan andere neuron in de volgende laag. Dit proces kan gebeuren in meerdere dimensies tegelijkertijd, op dat moment spreekt men van een tensormasker. Een voorbeeld van een convolutie in meerdere dimensies tegelijkertijd is een RGB afbeelding die in een keer door het netwerk gaat, waarbij de dimensies de rode, groene en blauwe pixels van het beeld zijn.

De verschillende inwendige lagen van een CNN zullen na training op zoek gaan naar features. Deze features kunnen eenvoudig zijn zoals randen en lijnen, maar kunnen ook complexer zijn specifiek voor de getrainde data. Elke laag genereert dus een soort featuremap, die gebruikt wordt als input voor de volgende laag van het netwerk.

Om uiteindelijk een classificatie te verkrijgen moet er een dimensievermindering doorgevoerd worden, dit wordt gedaan door 'pooling layers' aan het netwerk toe te voegen na elke convolutie laag. Dit heeft ook als effect dat de featuremaps vereenvoudigd worden, en het aantal gewichten beperkt blijft.

Een CNN kan pas gebruikt worden nadat het getraind is. Voor de training van een netwerk zijn er 2 dingen noodzakelijk: veel voorbeeld data en per voorbeeld de verwachte output (label). Bij het trainingsproces wordt alle inputdata aangelegd, en wordt er gekeken wat het netwerk aan zijn output heeft. De loss functie is een maat van hoe goed een netwerk een voorspelling kan doen van de input data, met andere woorden een vergelijking tussen de input en de output. Trainen van een netwerk is het optimaliseren van de gewichten bij de neuronen in elke laag van het netwerk, bij een optimaal resultaat is de loss functie minimaal. Dit is een complex probleem dat enkel kan lukken indien er genoeg trainingsdata ter beschikking is. Trainen kan gedaan worden d.m.v 'backpropagation'. Backpropagation is het steeds een klein beetje aanpassen van de gewichten bij de neuronen in het netwerk om de classificatie ten gevolge van de input, en het trainingslabel beter op elkaar af te stemmen. Dit proces werkt door de kettingregel toe te passen, en voor elke laag een voor een de gewichten te zoeken.

Een belangrijke laag in een CNN is de Rectified Linear Unit (ReLU). Deze laag voegt een niet lineaire functie toe tussen de convolutielagen, dit is nodig omdat de convolutie een lineaire operatie is, en een eigenschap van lineaire operators laat toe om deze te combineren tot 1 operator. Dit zou willen zeggen dat alle convoluties in een netwerk samengesteld kunnen worden tot 1 laag, en dus het voordeel van meerdere lagen wegnemen. Het toevoegen van een ReLU laag tussen elke convolutielaag voorkomt dit probleem.

Een voorbeeld van een CNN is het 'You Only Look Once (YOLO) detection system' [12]. Het YOLO netwerk is opgebouwd uit 24 convolutielagen en 2 'fully connected' lagen. Dit netwerk heeft een uitgebreide training gehad op de ImageNet dataset<sup>1</sup> en kan gebruikt worden om objectdetectie en -classificatie te doen door één keer de input afbeelding door het netwerk te laten gaan. Door middel van een hertraining kan deze detector leren om alle objecten te detecteren en te classificeren en dus een mogelijke detector zijn voor onze toepassing.

Zoals [9] voorstelt is het niet moeilijk om het 'YOLO detection system' een hertraining te geven om deuren te herkennen. Zo kan dit ook toegevoegd worden aan de lijst met te detecteren kenmerken.

## 2.3 Object tracking

Object tracking of het volgen van objecten heeft als doel het bepalen van de positie van hetzelfde object over meerdere frames heen. In het geval van dit onderzoek kan het een indicatie geven van relatieve posities t.o.v. objecten die zich in de gangen bevinden. Een grote moeilijkheid bij het volgen van objecten die stilstaan t.o.v. de camera is dat ze veranderen in grootte, oriëntatie en perspectief. [22] stelt voor om gebruik te maken van SIFT voor het volgen van objecten. Ze zoeken een Region Of Interest (ROI) op het eerste frame waarop ze een kleurhistogram en SIFT features berekenen. Op het volgende frame worden dezelfde bewerkingen uitgevoerd in een regio die net iets groter is dan de originele ROI. Een overeenkomstregio wordt dan berekend door middel van een Expectation-Maximization (EM) algoritme. Volgens [3] is het beter om gebruik te maken van het KLT feature algoritme [18]. Hiermee wordt er een transformatie berekend waardoor de ROI

---

<sup>1</sup><http://www.image-net.org>

tussen de 2 frames gelijkaardig wordt. De initiële transformatieparameters worden berekend via RANSAC.

[11] heeft een nieuwe techniek ontwikkeld om object tracking te combineren met object detectie CNN. Ze hebben een uitbreiding gemaakt op het YOLO detection system genaamd Recurrent YOLO (ROLO). De uitbreiding bevat een extra Long Short Term Memory Recurrent Neural Network (LSTM RNN) geplaatst achter de detectie fase van het originele netwerk. Een LSTM RNN is een neurale netwerk geoptimaliseerd voor het maken van beslissingen op tijdsgebaseerde data. De data die aan het extra netwerk gegeven wordt is een van de tussenresultaten van het YOLO netwerk. Het systeem blijkt zeer goed te werken voor het volgen van objecten zelfs bij oclusies in één van de beelden.


## 2.4 Image segmentation

Het correct segmenteren van de beelden zal een belangrijke rol spelen. Niet in elk beeld zal er een distinctief object aanwezig zijn om te detecteren. Daarom is het belangrijk om de vloer van de muren te kunnen onderscheiden. Een eenvoudige aanpak zou kunnen zijn om via K-means een verdeling van een beeld te doen en met een soort regressie de regio's te labelen. Volgens [21] werkt de K-means aanpak met een op textuur en kleur gebaseerde aanpak redelijk goed, maar wordt steeds de muur verbonden met het plafond omwille van kleur en textuurgelijkenissen. Hun regressie gebaseerde labeling techniek blijkt dus een slechte oplossing. Verder zoals [8] aangeeft zijn reflecties en overbelichting eigenschappen van indoor omgevingen die het moeilijk kunnen maken om een correcte segmentatie te doen. [8] stelt een techniek voor die begint met het detecteren van verticale en horizontale lijn segmenten. Dit doen ze door eerst een Canny edge detector[4] toe te passen en vervolgens een line fitting. Een zelf geleerde SVM classifier verdeelt alle lijnsegmenten in twee categorieën: horizontaal en verticaal. De vluchtlijnen van de gang worden hierbij onderverdeeld in de horizontale categorie. Alle lijnstukken krijgen een score via een reeks van operaties waarna enkel de beste lijnen bijgehouden worden. Op basis van de kleur van de vlakken tussen de lijnstukken kan een segmentatie gemaakt worden. Dit geeft een resultaat waarbij de vloer meestal een mooi homogeen geheel is, maar de muren in meerdere vlakken gesegmenteerd worden door eventuele kleurverschillen en objecten aan de muur.

Een andere manier om de vloer te segmenteren is voorgesteld in [14]. Zij doen een superpixel segmentatie volgens het SLIC algoritme [1], vervolgens bekijken ze de randen van de superpixels. Na observaties blijkt dat de randen van superpixels onregelmatig worden bij objectovergangen. Door het aanduiden van een paar vloerpixels kan hun algoritme superpixels aanduiden die tot de vloer behoren. Deze aanpak geeft een goede schatting van vrije ruimte op de vloer, maar is minder bruikbaar voor segmentatie van muren.

Een meer recente technologie om afbeeldingen te segmenteren is gebruik te maken van een CNN. Het netwerk voor segmentatie is verschillend van een traditioneel CNN voor bijvoorbeeld object detectie. Een voorbeeld van een segmentatienetwerk is te zien in figuur 2.2.

Het segmentatienetwerk SegNet [2] is een combinatie van convolutielagen en pooling layers. Er zijn




**Figuur 2.2:** Het SegNet [2] segmentatie netwerk.

geen fully connected layers aanwezig zoals het geval is bij een classificatie netwerk. De bedoeling van het SegNet netwerk is om als output opnieuw een afbeelding te genereren. Hiervoor zijn de lagen opgebouwd als een zandloper. Op deze manier is de output even groot als de oorspronkelijke afbeelding. Een segmentatienetwerk wordt getraind op gelijkaardige manier aan een traditioneel CNN met als verschil dat de labeling gebeurd op pixelbasis aangezien de output even groot is als de input van het systeem. Het systeem geeft als output een label voor elke pixel uit de afbeelding onderverdeeld in de klassen waarmee het systeem getraind is.

Het SegNet netwerk is getraind op de SUN RGB-D [16] dataset. Deze dataset bevat een groot aantal indoor scenes, waarbij er onder andere segmentatie klassen zijn voor muren, vloeren en plafonds. De training is gebeurd met enkel de RGB gegevens van de dataset. Deze segmentatietechniek zou nuttig kunnen zijn voor dit onderzoek om in beelden bijvoorbeeld de vloer te kunnen onderscheiden.

## Hoofdstuk 3

# Uitwerking



**Figuur 3.1:** Overzicht van het programma

Het doel van deze masterproef is om op basis van 1 RGB camera en een semantische kaart een robot autonoom te laten navigeren in de logistieke gangen van een ziekenhuis. Om dit te implementeren, is er een pipeline opgesteld. Deze pipeline is onderverdeeld in een aantal stappen die in de volgende hoofdstukken uitgebreid besproken worden.

### 3.1 Object detectie

Zoals besproken zal worden in hoofdstuk 3.4, bevat de semantische kaart van het ziekenhuis een beschrijving van objecten/features die aanwezig zijn in de gangen. Deze objecten zijn bijvoorbeeld:

- Lampen;

- Brandblussers;
- Pictogrammen;
- Rookdetectors;
- Deurklinken.

De gebruikte dataset zijn 2 video's opgenomen vanop een robot met de de waylens horizon<sup>1</sup> RGB camera. In dit beeldmateriaal zijn er een aantal van bovenstaande objecten zichtbaar, en kan er een detector gemaakt worden om deze features te herkennen.

De gekozen object detector is YOLOv2[13]. Dit is een zeer veel gebruikt object detectie/classificatie convolutioneel neuraal netwerk dat toelaat om objecten van een geleerde klasse te herkennen en lokaliseren in nieuwe beelden.

### 3.1.1 Annotatie beeldmateriaal

Om een object-detector te maken gebaseerd op een CNN moet al het beeldmateriaal geannoteerd worden door bounding-boxes te teken rondom de kenmerkende objecten. Elk van deze bounding-boxes moet ook voorzien worden van een bijhorend label. In tabel 3.1 is een opsomming gemaakt van alle annotaties in de training en validatie set.

**Tabel 3.1** Annotaties in training en validatie set

	Aantal frames	Rookmelder	Deurklink	Pictogram	TL-lamp	Totaal
Trainings set	899	1016	147	340	5260	6763
Validatie set	711	1130	180	408	992	2710

Voor het aanduiden van de annotaties is er gebruik gemaakt van de OpenCV Computer Vision Annotation Tool (CVAT)<sup>2</sup>. De output van de CVAT tool is een XML-bestand met voor elke afbeelding de coördinaten van de objecten. Een voorbeeld output voor 1 enkele afbeelding is te zien in listing 3.1.

**Listing 3.1:** Voorbeeld CVAT output

```
<image id="24" name="hospital_corridors_025.png" width="1280" height="720">
  <box label="door_handle" xtl="863" ytl="237" xbr="881" ybr="248"/>
  <box label="light" xtl="584" ytl="254" xbr="608" ybr="265"/>
  <box label="light" xtl="435" ytl="321" xbr="448" ybr="329"/>
  <box label="exit_sign" xtl="590" ytl="298" xbr="604" ybr="307"/>
</image>
```

De trainingsdata die aan het YOLO netwerk geleverd moet worden is in een volledig ander formaat dan het verkregen XML bestand, daarom is er een conversiescript geschreven om dit om te zetten naar het YOLO formaat. Het conversiescript bevindt zich in bijlage A. Het formaat dat YOLO

<sup>1</sup><https://waylens.com/horizon/techSpecs/>

<sup>2</sup><https://github.com/opencv/cvat>

verwacht is per input afbeelding een .txt bestand met daarin per lijn een bounding box. Het YOLO formaat is beschreven in 3.1 waarbij  $\langle x \rangle$  en  $\langle y \rangle$  het centerpunt van een bounding box zijn. Alle waarden zijn genormaliseerd, dit wil zeggen dat om het absolute  $(x, y)$  coördinaat te bekomen, de waardes vermenigvuldigd moeten worden met de breedte en de hoogte zoals geïllustreerd in 3.2.

$$\langle x \rangle \langle y \rangle \langle width \rangle \langle height \rangle \quad (3.1)$$

$$\begin{aligned} x_{abs} &= \langle x \rangle * image\_width \\ y_{abs} &= \langle y \rangle * image\_height \end{aligned} \quad (3.2)$$

### 3.1.2 Training YOLOv2

Voor training en later ook detectie met YOLOv2 is er gebruikt gemaakt van een aangepaste versie van de darknet<sup>3</sup> implementatie in C. We zijn vertrokken van het yolo-voc.2.0.cfg configuratie bestand waar we het aantal te detecteren klassen hebben aangepast naar 4 (light, smoke\_detector, exit\_sign en door\_handle), en het aantal filters naar 25. Dit nieuw configuratie bestand specificeert de netwerk layout, deze layout is een YOLOv2 netwerk waarbij nu de laatste lagen aangepast zijn om slechts 4 objecten te classificeren.

Het trainen gebeurt nu op basis van de traininsset zoals weergegeven in tabel 3.1. De performantie van het netwerk zal besproken worden in hoofdstuk 4.

## 3.2 Perspectiefpunt detectie

In hoofdstuk 3.3 zullen we bespreken hoe het lokaliseren werkt, om dit te realiseren wordt er gebruik gemaakt van het perspectiefpunt. Het detecteren van het perspectiefpunt kan gebeuren op verschillende manieren, voor dit onderzoek zijn drie verschillende technieken geïmplementeerd, en deze zullen verder besproken worden.

De performantie en nauwkeurigheid van de 3 methoden zal besproken worden in hoofdstuk 4.

### 3.2.1 Hoogste vloerpixel segmentatie

De eerste techniek maakt gebruik van het DeepLab-ResNet [5] segmentatienetwerk gelijkaardig aan de beschrijving in hoofdstuk 2.4. Het netwerk is geïmplementeerd in TensorFlow en voorge-traind op indoor scenes zodat het klaar is voor gebruik in python.<sup>4</sup>

Het netwerk kan gebruikt worden om in een afbeelding elke pixel onder te verdelen in een aantal klassen zoals: muur, vloer, boom, meubel en trap. Voor het detecteren van het perspectiefpunt hebben we gekozen om enkel de vloerpixels te gebruiken. Het resultaat van de segmentatie is

<sup>3</sup><https://github.com/AlexeyAB/darknet>

<sup>4</sup><https://github.com/hellochick/Indoor-segmentation>





**Figuur 3.2:** ResNet segmentatie van 1 input frame.

te zien in figuur 3.2 waarbij groen vloerpixels zijn, roze muurpixels, grijs plafondpixels en blauw meubelpixels.

Van de gesegmenteerde data nemen we dan de hoogste vloerpixel, en deze gebruiken we als perspectiefpunt.


### 3.2.2 Vloerlijn kruising

Voor deze techniek maken we gebruik van dezelfde segmentatiedata als in hoofdstuk 3.2.1, maar wordt er een masker gemaakt met enkel de vloerpixels. Op dit masker wordt door middel van een Canny-edgedetector de rand van de vloer gedetecteerd, dit proces is gevisualiseerd in figuur 3.3. Vervolgens kunnen er door middel van de Hough-transformatie een aantal rechten gevonden worden die raken aan zoveel mogelijk punten met de rand van de vloer. Zoals te zien in figuur 3.3 worden er meerdere rechten gevonden, en deze moeten gefilterd worden omdat ze ongeveer dezelfde lijn voorstellen. Dit gebeurt door de richtingscoëfficiënt van alle lijnen met elkaar te vergelijken, en indien het verschil te klein is, wordt de lijn met de laagste richtingscoëfficiënt verwijderd. Het optimale resultaat is dat er 1 lijn overblijft aan elke kant van de vloer, zodat deze de vluchtlijnen voorstellen. Indien dit het geval is, is de kruising van de 2 rechten het perspectiefpunt.


### 3.2.3 Perspectieflijn kruising

Deze techniek lijkt sterk op de beschreven methode uit 3.2.2 met als verschil dat hier geen gebruik gemaakt wordt van vloersegmentatie. De gehele afbeelding wordt omgezet naar grijswaarden voordat het door een Canny-edgedetector gehaald wordt met een variabele threshold gebaseerd op de mediaan van de grijswaarden. De edge detectie wordt wederom gebruikt om door middel van de Hough-transformatie een aantal aanliggende rechten te zoeken die zoveel mogelijk punten snijdt. We zijn op zoek naar perspectieflijnen, dus alle horizontale en verticale lijnen worden onmiddellijk verwijderd net als rechten waarvan de richtingscoëfficiënt niet genoeg van elkaar afwijkt. Dit is weergegeven in figuur 3.4.

Indien er slechts een paar lijnen overschieten na filtering, kan gesteld worden dat het perspectiefpunt te vinden is op de kruising van de rechten.




**Figuur 3.3:** **Linksboven:** vloersegmentatie, **Rechtsboven:** Canny-edgedetectie, **Linksonder:** alle Hough lijnen, **Rechtsonder:** filtering van lijnen



**Figuur 3.4:** **Links:** Canny-edgedetectie op hele afbeelding. **Rechts:** Hough lijnen uit edge detectie.

### 3.3 Omgevingsmeting



**Figuur 3.5:** Schematische voorstelling omgevingsmeting

Door middel van de RGB camerabeelden genomen van het standpunt van de robot, willen we een representatie maken van de omgeving. Deze representatie zal later gebruikt worden om de actuele locatie van de robot te volgen. Voor het opbouwen van de omgeving maken we gebruik van de object detector beschreven in hoofdstuk 3.1. De detector geeft een lijst terug van objecten met voor elk object een begrenzendende rechthoek en een klasse. Elk object heeft een unieke locatie in het beeld, en dus ook in de ruimte.

In figuur 3.5 is een schematische 2d voorstelling te zien van een gang waarin er zich 3 objecten bevinden, 2 van deze objecten bevinden zich binnen de kijkhoek van de camera, en worden door middel van de rode stippellijnen geprojecteerd op het blauwe cameravlak.

De rode stippen zichtbaar in 3.5 zijn de coördinaten van de objecten zoals ze gedetecteerd worden door de object detector. Het doel is om op basis van deze coördinaten de hoek  $\alpha_i$  tussen de optische as van de camera en het object in de ruimte te bepalen.

Hiervoor komt het perspectiefpunt vanpas, het perspectiefpunt licht in de figuur op een oneindige afstand op de zwarte stippelijn(optische as). De pixelafstand volgens de x-as van de optische as

tot het centrum van de bounding box van een object is gedefinieerd als  $x_i$ .

Formule 3.3 toont dat voor het verband tussen  $x_i$  gemeten in pixels en  $\alpha_i$  een extra constante parameter  $l_f$  nodig is.  $l_f$  is één van de camera specifieke parameters, die de afstand tussen de camerasensor en het beeldvlak definieert, namelijk de focale lengte of brandpuntsafstand. Deze parameter kan verkregen worden door middel van een cameracalibratie, en moet omgerekend worden naar pixels.

$$\alpha_i = \tan^{-1}\left(\frac{x_i}{l_f}\right) \quad (3.3)$$

### 3.3.1 Camera kalibratie

## 3.4 Semantische kaart

## 3.5 Lokalisatie

## **Hoofdstuk 4**

# **Resultaten**

## **Hoofdstuk 5**

### **Besluit**

## Bibliografie

- [1] R. Achanta, A. Shaji, K. Smith, A. Lucchi, P. Fua, and S. Šštrunk. Slic superpixels compared to state-of-the-art superpixel methods. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 34(11):2274–2282, Nov 2012.
- [2] Vijay Badrinarayanan, Alex Kendall, Roberto Cipolla, and Senior Member. SegNet : A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation. pages 1–14.
- [3] Bhakti Baheti, Ujjwal Baid, and Sanjay Talbar. An approach to automatic object tracking system by combination of SIFT and RANSAC with mean shift and KLT. *Conference on Advances in Signal Processing, CASP 2016*, pages 254–259, 2016.
- [4] J. Canny. A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8(6):679–698, Nov 1986.
- [5] L. Chen, G. Papandreou, I. Kokkinos, K. Murphy, and A. L. Yuille. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 40(4):834–848, April 2018.
- [6] Chiung Yao Fang, Sei Wang Chen, and Chiou Shann Fuh. Road-sign detection and tracking. *IEEE Transactions on Vehicular Technology*, 52(5):1329–1341, 2003.
- [7] Peter Henry, Michael Krainin, Evan Herbst, Xiaofeng Ren, and Dieter Fox. Rgb-d mapping: Using depth cameras for dense 3d modeling of indoor environments. In *In the 12th International Symposium on Experimental Robotics (ISER)*, 2010.
- [8] Yinxiao Li and Stanley T. Birchfield. Image-based segmentation of indoor corridor floors for a mobile robot. *IEEE/RSJ 2010 International Conference on Intelligent Robots and Systems, IROS 2010 - Conference Proceedings*, pages 837–843, 2010.
- [9] Adrian Llopart, Ole Ravn, and Nils A. Andersen. Door and cabinet recognition using Convolutional Neural Nets and real-time method fusion for handle detection and grasping. *2017 3rd International Conference on Control, Automation and Robotics, ICCAR 2017*, pages 144–149, 2017.
- [10] D G Lowe. Object recognition from local scale-invariant features. In *Proceedings of the Seventh IEEE International Conference on Computer Vision*, volume 2, pages 1150–1157 vol.2, sep 1999.

- [11] Guanghan Ning. Spatially Supervised Recurrent Convolutional Neural Networks for Visual Object Tracking. (1):1–4, 2017.
- [12] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun 2016.
- [13] Joseph Redmon and Ali Farhadi. Yolo9000: Better, faster, stronger. *arXiv preprint arXiv:1612.08242*, 2016.
- [14] F. Geovani Rodríguez-Telles, L. Abril Torres-Méndez, and Edgar A. Martínez-García. A fast floor segmentation algorithm for visual-based robot navigation. *Proceedings - 2013 International Conference on Computer and Robot Vision, CRV 2013*, pages 167–173, 2013.
- [15] K. Schmid, T. Tomic, F. Ruess, H. Hirschmüller, and M. Suppa. Stereo vision based indoor/outdoor navigation for flying robots. In *2013 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 3955–3962, Nov 2013.
- [16] Shuran Song, Samuel P. Lichtenberg, and Jianxiong Xiao. Sun rgb-d: A rgb-d scene understanding benchmark suite. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2015.
- [17] R. Swathika and T. S. Sharmila. Emergency exit sign detection system for visually impaired people. In *2016 International Conference on Inventive Computation Technologies (ICICT)*, volume 1, pages 1–7, Aug 2016.
- [18] Carlo Tomasi and Takeo Kanade. Detection and tracking of point features. 1991.
- [19] M Tomono and S Yuta. Mobile robot navigation in indoor environments using object and character recognition. In *Proceedings 2000 ICRA. Millennium Conference. IEEE International Conference on Robotics and Automation. Symposia Proceedings (Cat. No.00CH37065)*, volume 1, pages 313–320 vol.1, apr 2000.
- [20] S. J. Zabihi, S. M. Zabihi, S. S. Beauchemin, and M. A. Bauer. Detection and recognition of traffic signs inside the attentional visual field of drivers. *IEEE Intelligent Vehicles Symposium, Proceedings*, (lv):583–588, 2017.
- [21] Zhong-Ju Zhang. Wall, floor, ceiling, object region identification from single image.
- [22] Huiyu Zhou, Yuan Yuan, and Chunmei Shi. Object tracking using SIFT features and mean shift. *Computer Vision and Image Understanding*, 113(3):345–352, 2009.



## Bijlage A

# CVAT naar YOLO conversie

```
import xml.etree.ElementTree as ET
import argparse
import os

parser = argparse.ArgumentParser()
parser.add_argument("file")
args = parser.parse_args()

classes = []

def getLabels(root):
    labels = root.find('task').find('labels')

    for label in labels:
        classes.append(label.find('name').text)

    with open('cust.names', 'w') as names:
        names.write("\n".join(classes))

if __name__ == '__main__':
    tree = ET.parse(args.file)
    root = tree.getroot()

    print(root.tag)

    if not os.path.isdir('Anotations.yolo'):
        os.mkdir('Anotations.yolo')

    for child in root:
        if child.tag == 'meta':
            getLabels(child)

        if child.tag == 'image':
            image = child.get('name')
            w = float(child.get('width'))
            h = float(child.get('height'))

            boxes = ''
            for box in child.findall('box'):
                xtl = float(box.get('xtl'))
                ytl = float(box.get('ytl'))
                xbr = float(box.get('xbr'))
                ybr = float(box.get('ybr'))

                width = xbr - xtl
                height = ybr - ytl
                x = xtl + (width/2)      #center
                y = ytl + (height/2)

                boxes += '{0}-{1}-{2}-{3}\n'.format(classes.index(box.get('label')),
                                                       x/w, y/h, width/w, height/h)

    with open('Anotations.yolo/{0}.txt'.format(os.path.splitext(image)[0]), 'w') as file:
```

```
file.write (boxes)
```

FACULTEIT INDUSTRIËLE INGENIEURSWETENSCHAPPEN  
CAMPUS DE NAYER SINT-KATELIJNE-WAVER  
J. De Nayerlaan 5  
2860 SINT-KATELIJNE-WAVER, België  
tel. + 32 15 31 69 44  
iiw.denayer@kuleuven.be  
[www.iw.kuleuven.be](http://www.iw.kuleuven.be)

